

K-Anonymity 與 PCA 對 ML 效能影響實驗報告

1. 實驗目的 (Introduction)

- 背景： K -Anonymity 是數據隱私保護的核心技術，透過將特定屬性群組化（Generalization）來達到去識別化。然而，隨著 K 值（隱私保護強度）增加，數據的模糊化通常會導致機器學習模型的效能顯著下降。
- 研究問題：
 - 探討在 Mondrian 演算法下，模型效能隨 K 值增加的衰減幅度。
 - 引入 PCA 降維後，是否能透過保留特徵間的相關性，在高隱私強度下緩解效能損失。
- 評估模型：對比 SVM 與 MLP。
- 評估指標：Accuracy, Misclassification Rate, Precision, Recall, and AUC

2. 實驗方法 (Methodology)

2.1 數據處理流程

- 數據集：使用 UCI Adult Dataset。
- 預處理：
 - 有屬性缺失的資料直接丟棄，`fnlwgt` 欄位無實質意義故一併移除
 - 類別型特徵以 `LabelEncoder` 進行編碼，其中預測欄 `income > 50K` 編為 1，`≤ 50K` 編為 0
- 匿名化策略：
 - Raw Mode：
 - 直接在原始特徵空間進行 Mondrian 切割，並以分區中位數填充。
 - PCA Mode：
 - 執行 `StandardScaler` 標準化後，將數據投影至 PCA 空間（保留 95% 變異量）。
 - 在 PCA 空間進行 Mondrian 切割並充充分區中位數。
 - 執行 **Inverse Transform** 還原回原始空間，並使用 `clip(lower=0)` 修正物理意義錯誤（如年齡不為負）。

4. 隱私強度設定 (K 值) :

1 (基準值 , 不匿名處理) , 10, 50, 100, 200

2.2 模型架構

兩種模式的訓練數據於送入模型前 , 均會執行 `StandardScaler` 標準化。

- **SVM:**

- 使用 Scikit-learn 的 `svc` 實作。為了獲取 AUC 指標 , 開啟了 `probability=True` 設定。

- **MLP:**

- 基於 PyTorch 實作的 DL。
- **核心結構** : 採用 **ResNet-like** 架構 , 包含 2 個 **Residual Blocks**。
- **激發函數** : 使用 `LeakyReLU` 避免 Dying ReLU 問題。
- **正則化** : 加入 `Dropout` 層防止過擬合。

2.3 模型參數設定

採用 **Grid Search** 針對 $K = 1$ 的原始數據進行參數調優 , 並將該組最佳參數套用於其餘所有 K 值實驗。

- **SVM:**

- 搜尋 : C : [0.1, 1, 10], $gamma$: ['scale', 0.1, 0.01]
- 最後固定 : Kernel = RBF , $C = 10$, $gamma = scale$

- **MLP:**

- 搜尋 : lr : [0.001, 0.002, 0.005], dropout : [0.1, 0.2, 0.3]
- 最後固定 : epochs = 60, batch_size = 128, lr = 0.002, dropout = 0.1





3. 實驗結果與分析 (Results and Analysis)

3.1 實驗數據彙整

以下呈現原始空間 (Raw Mode) 與 PCA 空間 (PCA Mode) 在不同 K 值下的模型效能對照。





RAW Mode:

K	Model	Accuracy	Miss	Precision	Recall	AUC
1	MLP	0.8635	0.1365	0.7514	0.6751	0.9251
1	SVM	0.8616	0.1384	0.7928	0.6014	0.9159
10	MLP	0.8210	0.1790	0.7877	0.3845	0.8357
10	SVM	0.8178	0.1822	0.8559	0.3221	0.7656
50	MLP	0.8117	0.1883	0.8301	0.3065	0.8106
50	SVM	0.8089	0.1911	0.8286	0.2929	0.7183
100	MLP	0.8087	0.1913	0.8506	0.2806	0.7972
100	SVM	0.8085	0.1915	0.8498	0.2804	0.6618
200	MLP	0.8035	0.1965	0.8724	0.2467	0.7776
200	SVM	0.8035	0.1965	0.8724	0.2467	0.6133



PCA Mode:

K	Model	Accuracy	Miss	Precision	Recall	AUC
1	MLP	0.8633	0.1367	0.7454	0.6847	0.9243
1	SVM	0.8605	0.1395	0.7921	0.5959	0.9141
10	MLP	0.8260	0.1740	0.6907	0.5452	0.8780
10	SVM	0.8254	0.1746	0.7230	0.4842	0.8393
50	MLP	0.8103	0.1897	0.6825	0.4449	0.8500
50	SVM	0.8101	0.1899	0.6886	0.4326	0.7560
100	MLP	0.8056	0.1944	0.6659	0.4393	0.8355
100	SVM	0.8046	0.1954	0.6902	0.3903	0.7090
200	MLP	0.7905	0.2095	0.6260	0.3933	0.8115
200	SVM	0.7912	0.2088	0.6282	0.3946	0.6698



3.2 數據討論與發現

A. K 值對模型效能的負面影響

從兩組數據中皆可觀察到，隨著 K 值的增加，所有模型的指標 (Accuracy, Recall, AUC) 均呈現下降趨勢。這是因為 K -Anonymity 的中位數填充機制模糊了個體特徵，導致模型難以從模糊的特徵中萃取有效的分類信號。特別是 **SVM**，在 $K = 200$ 時其 AUC 跌至 **0.6133** (Raw) 與 **0.6698** (PCA)，顯示傳統核函數模型對大面積數據重疊的適應性較差，容易喪失區分支持向量的能力。

B. PCA 在高隱私強度下的「效能拯救」作用

本實驗最關鍵的發現是：在 $K > 50$ 之後，**PCA** 模式的 **Recall** 與 **AUC** 顯著優於 **Raw** 模式。

在 $K = 200$ 時，PCA 版 MLP 的 Recall (**0.3933**) 遠高於 Raw 版 (**0.2467**)。

Raw 模式在原始特徵軸 (如年齡、薪資) 進行切割，容易破壞特徵間的相關性。而 PCA 透過主成分投影，將數據投影至變異量最大的軸向。在 PCA 空間進行 Mondrian 分割，能確保被劃分在同一個群體內的樣本在「特徵結構」上更為相似，進而保留了更多用於分類的關鍵信號，減緩了匿名化造成的資訊損失。

C. MLP (ResNet) 的魯棒性優勢

在所有實驗組別中，**Advanced MLP (ResNet)** 的表現始終優於 **SVM**。

- **殘差結構的作用**：透過 2 個 Residual Blocks，MLP 能夠更有效地學習到數據被模糊化後的非線性特徵。
- **容錯能力**：神經網路透過權重分配與 Dropout，能自動過濾部分由匿名化產生的雜訊。相比之下，SVM 極度依賴支持向量的精確度，一旦數據在大 K 值下產生大量重疊，SVM 的辨識能力便會迅速崩潰。

D. Precision 與 Recall 的權衡 (Trade-off)

觀察 **Precision** 與 **Recall** 的對照趨勢圖，可以發現一個有趣的對比現象：

1. Raw Mode 的「保守預測」效應：

在原始空間中，隨著 K 值增加，Precision 竟呈現逆勢上升 (在 $K = 200$ 時，MLP 達到最高點 **0.8724**)。這並非代表模型變強，而是因為數據在原始維度被大幅模糊後，特徵信號極其微弱，導致模型預測行為變得**極度保守**。模型僅對極少數 (且特徵極端明確) 的樣本判定為正類，雖然導致了 **Recall** (召回率) 的斷崖式下跌，但也因「只抓最有把握的樣本」而意外提升了 **Precision** (精確度)。

2. PCA 模式的「全局特徵保留」：

相比之下，PCA 模式的 Precision 曲線雖然位居下方，但這反映了模型在嘗試捕捉更完整的數據分佈。PCA 在主成分空間進行切割，保留了特徵間的相關結構，使模型在高 K 值下仍能感知正類的存在，維持預測正類的意願。Precision 較低是主動權衡的結果——模型選擇覆蓋更廣的正類候選，而非僅預測最有把握的少數樣本。

3. 綜合評估：召回率的實務價值：

在 $K = 200$ 的極端隱私環境下，PCA 版 MLP 的 **Recall (0.3933)** 遠優於 Raw 版的 **(0.2467)**。在隱私數據分析（如金融風控或疾病篩檢）的實務應用中，這種「能夠在大範圍模糊中依然抓出目標」的召回能力與 **AUC（整體排序能力）**，通常比 Raw Mode 以犧牲覆蓋率換取的虛高 Precision 更具參考價值。

4. 實務應用導向：高精確度 (Precision) 的決策價值

儘管 PCA 模式在整體數據效用（Recall 與 AUC）上表現優異，但從**實務資源分配**的角度來看，Raw Mode 在高 K 值下展現的極高 Precision 反而更具優勢。若業務目標是「以最少的人力與行銷成本，精準鎖定最高潛力的客戶」，則 **Raw Mode** 是更佳選擇。

因此，模式的選擇本質上取決於實際目標對 FN 與 FP 的容忍程度：若不容許遺漏目標（如疾病篩檢、詐欺偵測），PCA 模式的高 Recall 與 AUC 更具價值；若資源有限且要求每次預測高度精準（如精準行銷），Raw Mode 的高 Precision 則更為適合。

4. 結論 (Conclusion)

1. **隱私與效能的取捨**：實驗證實 K -匿名化確實會造成效能損失，但損失程度取決於切割空間的選擇。
2. **PCA 的優越性**：在高隱私需求（大 K 值）場景下，**PCA + 逆轉換** 模式能有效保留特徵相關性，減緩 Recall 與 AUC 的損失幅度。
3. **模型選擇建議**：
 - **技術選型**：針對匿名化後的模糊數據，DL 在穩定性與預測上限上皆遠優於傳統 SVM，是隱私計算場景下更理想的模型選擇。
 - **實務權衡**：匿名化策略應視實際需求而定。若追求「全面覆蓋」與數據完整性，應優先採用 **PCA 模式**；若目標為對精確度要求較高，則 **Raw Mode** 在高 K 環境下的高 Precision 特性亦具備特定的實務適用價值。